


PROYECTO ENTORNOS DATAWAREHOUSE

AUTOR: Adrián Robles Arques

En MongoDB Atlas deberemos hacer lo siguiente:

- Crear la base de datos “proyecto” en nuestro cluster creado (si no se tiene habrá que crearlo).



The screenshot shows the 'Create Database' dialog box in MongoDB Atlas. It has a title bar with a close button (X). The dialog contains two input fields: 'Database Name' with the value 'proyecto' and 'Collection Name' with the value 'ventas'. Below the 'Collection Name' field is a checkbox labeled 'Time-Series' which is unchecked. Underneath this checkbox is a description: 'Time-series collections efficiently store sequences of measurements over a period of time. [Learn More](#)'. Below this is a section titled 'Additional preferences (e.g. Custom collation, Clustered collections)' with a right-pointing chevron icon. At the bottom right of the dialog are two buttons: 'Cancel' and 'Create Database'.


Accedemos a la opción para crear una nueva base de datos en MongoDB atlas, creamos la base de datos “proyecto” y la primera colección, en nuestro caso “ventas”.

- Crear la colección “ventas” dentro de nuestra base de datos “proyecto”.

Ya creado en el paso anterior, dado que se debe crear una colección dentro de la base de datos al crear esta.

- Crear la colección “videojuegos” dentro de nuestra base de datos “proyecto”.

Una vez creada la base de datos, accedemos a la opción de “Crear colección” para añadir una nueva colección.



Create Collection

Collection Name

videojuegos


☐ **Time-Series**

Time-series collections efficiently store sequences of measurements over a period of time. [Learn More](#)

➤ **Additional preferences** (e.g. Custom collation, Clustered collections)

Cancel Create Collection

- Importar los datos de los ficheros aportados en el proyecto (deberíais de ver 2 de ventas y 2 de videojuegos, uno en formato csv y otro en formato json).



Desde cada una de las colecciones, aún vacías, seleccionamos la opción de “Importar JSON o CSV” desde el botón “Añadir datos”. Añadimos ambos archivos para cada colección.

- Conectar el Data Federation con nuestro cluster introduciendo la base de datos “proyecto”.

ADRIAN'S ORG - 2025-02-20 > PROJECT 0

Data Federation

Query and transform data wherever it lives



MOST POPULAR CHOICE

Feed Downstream Systems

Export your Atlas data to Parquet, CSV, BSON, or Extended JSON, and use it in your downstream systems using AWS S3.

Export your data



Explore Atlas Data Federation with Sample Data

See how easy it is to gain insights into your business by connecting and transforming data from multiple sources.

Connect sample data

Manage Query Limits

Create New Federated Database

Feed Downstream Systems
Export your data to Parquet, CSV, BSON, or Extended JSON and land it in Object Storage.

Explore with Sample Data
Try it with sample data preloaded into cloud object storage.

Query Data Across Clusters
Access and query data with a single connection.

Set up manually
Manually configure your Federated Database Instance.

Query clusters

Creamos un nuevo Data Lake desde el servicio de “Data Federation”, escogiendo la opción de configurarlo manualmente. Vamos a escoger nuevamente AWS como proveedor del servicio y MongoDB Atlas como fuente de los datos.

1

2

Cloud Provider & Name

Data Source

Cloud Provider

This is the location your data will be processed when you query your federated database instance. You'll usually want to choose the same cloud provider as the one that hosts your data.

Note: You won't be able to change the cloud provider once you've set up your federated database.

aws

Azure

Google Cloud

Federated Database Instance Name


Note: Once your federated database instance is created, you won't be able to change its name.

DataLake-Proyecto

Add Data Source

Choose Your Data Store to Get Started

[View Data Federation Docs](#)



Choose the Atlas clusters that you would like to access in your Federated Database instance.

Provide Namespaces in this project


IEBS ▼

Search for database or collection ...

- ▼ ☒ Proyecto
- ☒ ventas
- ☒ videojuegos

En MongoDB seleccionamos la base de datos “Proyecto” y las dos colecciones que incluye.

- Crear la base de datos “proyecto” en el Data Lake.
- Crear la colección “ventas” y “videojuegos” en la base de datos “proyecto” del Data Lake.
- Poner todos los datos de nuestras colecciones “ventas” y “videojuegos” a las del Data Federation.



En la siguiente pestaña de configuración, eliminamos las colecciones y base de datos predefinida, creamos una base de datos “Proyecto” en el Data Lake, con dos colecciones homónimas a las que tenemos en el cluster, asignando dichas colecciones según vemos en la imagen.

- Conectarnos desde MongoDB Compass.

Configuramos la conexión seleccionando la URI que nos proporciona Atlas e insertándola en Compass, junto con nuestra contraseña en el sitio asignado, de modo que podemos acceder desde Compass a los datos solicitados.

Sort by Collection Name



View



Ventas

READ-ONLY

Storage size:

Documents:

Avg. document size:

Indexes:

Total index size:

Videojuegos

READ-ONLY

Storage size:

Documents:

Avg. document size:

Indexes:

Total index size:

- Hacer una query a cada conjunto (ver la colección “ventas” es una concatenación de los datos que tenemos más los públicos).

videojuegos					
_id	ObjectId	nombre	String	consola	String
id	Mixed				
1	ObjectId('67ebb6a240a0c00...	"Mario y Luigi"		"nintendo"	
2	ObjectId('67ebb6a240a0c00...	"The last of us"		"play"	
3	ObjectId('67ebb6a240a0c00...	"Sony"		"sega"	
4	ObjectId('67ebb6a240a0c00...	"Forza Horizon"		"xbox"	
5	ObjectId('67ebb6a240a0c00...	"lol"		"pc"	
6	ObjectId('67ebb6a240a0c00...	"Kirbi"		"nintendo"	
7	ObjectId('67ebb6ab40a0c00...	"wario"		"nintendo"	
8	ObjectId('67ebb6ab40a0c00...	"uncharted"		"play"	

Documents

N/A

Aggregations

Schema

Indexes

N/A

Validation

Type a query: { field: 'value' } or [Generate query](#)[EXPORT DATA](#)

Ventas

	_id	ObjectId	id_juego	Mixed	unidades	Mixed
1	ObjectId('67ebb68740a0c00...		2		10	
2	ObjectId('67ebb68740a0c00...		3		20	
3	ObjectId('67ebb68740a0c00...		4		5	
4	ObjectId('67ebb68740a0c00...		5		1	
5	ObjectId('67ebb68740a0c00...		1		4	
6	ObjectId('67ebb68e40a0c00...		"1"		"2"	
7	ObjectId('67ebb68e40a0c00...		"5"		"6"	

Mostramos todos los datos de ambas colecciones, vemos que hay formatos mezclados.

- Utilizar las operaciones disponibles en “Aggregation” de MongoDB Compass para conseguir:
 - Las unidades vendidas totales de cada juego.

Empleamos la siguiente pipeline:

```
[
  {
    $set: {
      id_juego: {
        $toInt: "$id_juego"
      }
    }
  },
  {
    $set: {
      unidades: {
        $toInt: "$unidades"
      }
    }
  },
  {
    $group: {
      _id: "$id_juego",
      unidades: {
        $sum: "$unidades"
      }
    }
  },
  {
    $set: {
      id_juego: "$_id"
    }
  },
  {
    $project: {
      _id: 0
    }
  },
  {
    $lookup: {
      from: "videojuegos",
      localField: "id_juego",
      foreignField: "id",
      as: "videojuego"
    }
  },
]
```

```

{$set:
  {
    nombre_juego: {
      $first: "$videojuego.nombre"
    }
  }
},
{$set:
  {
    consola: {
      $first: "$videojuego.consola"
    }
  }
},
{$project:
  {
    videojuego: 0,
    id_juego: 0
  }
}
]

```

Obtenemos el siguiente resultado:

\$set

\$set

\$group

\$set

\$project

\$lookup

\$set

\$set

\$project

Edit

Explain

Export

Run

Options

ALL RESULTS

Showing 1 – 5 count results

unidades : 5

nombre_juego : "Forza Horizon"

consola : "xbox"

unidades : 10

nombre_juego : "The last of us"

consola : "play"

unidades : 6

nombre_juego : "Mario y Luigi"

consola : "nintendo"

unidades : 20

nombre_juego : "Sony"

consola : "sega"

unidades : 7

nombre_juego : "lol"

consola : "pc"

- Las unidades vendidas totales de cada consola

Usando la siguiente pipeline:

```
[
  {$set:
    {
      id_juego: {
        $toInt: "$id_juego"
      }
    }
  },
  {$set:
    {
      unidades: {
        $toInt: "$unidades"
      }
    }
  },
  {
    $group:
    {
      _id: "$id_juego",
      ventas: {
        $sum: "$unidades"
      }
    }
  },
  {$lookup:
    {
      from: "Videojuegos",
      localField: "_id",
      foreignField: "id",
      as: "videojuego"
    }
  },
  {$set:
    {
      consola: {
        $first: "$videojuego.consola"
      }
    }
  },
  {$group:
    {
      _id: "$consola",
      Ventas: {
        $sum: "$ventas"
      }
    }
  }
]
```

```

    },
    {$set:
      {
        consola: "$_id"
      }
    },
    {$project:
      {
        _id: 0
      }
    }
  }
]

```

Obtenemos el siguiente resultado:

ALL RESULTS Showing 1 – 5 count results

Ventas : 20 consola : "sega"
Ventas : 6 consola : "nintendo"
Ventas : 10 consola : "play"
Ventas : 5 consola : "xbox"
Ventas : 7 consola : "pc"

OPCIONAL

Añadir un fichero de ventas en AWS, ventas.csv en un S3 propietario del alumno, conectarlo con el Data Federation de MongoDB haciendo que cambie el resultado final (o que se muestren datos nuevos).

Creamos un nuevo fichero llamado “ventas-2.csv” con dos entradas de ventas más. A continuación creamos un nuevo “Bucket” en AWS, en el cual vamos a añadir una carpeta de “ventas” a la que subiremos el documento:

Crear carpeta [Información](#)

Utilice carpetas para agrupar los objetos en buckets. Al crear una carpeta, S3 creará un objeto con el nombre que usted especifique seguido de una barra inclinada (/). Este objeto luego aparecerá como una carpeta en la consola. [Más información](#)

ⓘ Su política de bucket podría bloquear la creación de carpetas

Si su política de bucket impide cargar objetos sin etiquetas, metadatos o beneficiarios específicos de la lista de control de acceso (ACL), no podrá crear una carpeta con esta configuración. En su lugar, puede utilizar la [configuración de carga](#) para cargar una carpeta vacía y especificar la configuración adecuada.

Carpeta

Nombre de la carpeta

Los nombres de las carpetas no pueden contener "/" Consultar las reglas de nomenclatura

Cargar [información](#)

Agregue los archivos y las carpetas que desea cargar en S3. Para cargar un archivo de más de 160 GB, utilice la CLI de AWS, los SDK de AWS o la API REST de Amazon S3. [Más información](#)

Arrastre y suelte aquí los archivos y carpetas que desee cargar, o seleccione **Add files** (Agregar archivos) o **Add folder** (Agregar carpeta).

Archivos y carpetas (1 total, 29.0 B)

Se cargarán todos los archivos y las carpetas de esta tabla.

🔍

Eliminar

Agregar archivos

Agregar carpeta

< 1 >


☒	Nombre	Carpeta	Tipo	Tamaño
☒	vnetas-2.csv	-	text/csv	29.0 B

A continuación procedemos a conectar esta nueva fuente de datos al Data Lake que ya teníamos creado:

Add Data Source

Choose Your Data Store to Get Started

[View Data Federation Docs](#)



Connect to AWS S3 and then map files from your S3 bucket to your Federated Database instance.

We'll guide you through the set up process

1. Setup an AWS IAM role for Data Federation access.
2. Grant access to the S3 bucket where you want to query and write data.
3. [Map data in S3 to virtual Databases and Collections](#) using our tools.

Cancel

Next

Empleamos la opción “Añadir fuente de datos” y seleccionamos Amazon S3 como origen.

Configure AWS S3 Data Store



Enter Your S3 Bucket

[View AWS S3 Docs](#)

Enter the name of the S3 bucket that you want Atlas to access. In the next step, you will be asked to create an access policy to grant Atlas the required AWS IAM role access to your buckets.

Bucket Name

Enter the S3 Bucket you want Atlas to query

- ☒ Read-only
- ☐ Read and write

Prefix

This string will be prepended to all paths you define for this bucket

Back

Cancel

Next

Data Sources

Example S3 Path

Enter an example S3 Path from your bucket in AWS Console.


Link S3 Path Components

Assign a query parameter name and type to the section of your S3 path. Additionally, select static for a section of the path to remain the same or "any value" to include any value of that path in all queries.


bucket: mongodb-iebs-df-adrianrobles, Prefix: ventas/

Path for Data Lake Storage Config: /vnetas-2.csv


Configuramos la fuente de datos para enlazar con el servidor de Amazon S3 y después la añadimos a la colección ventas:



En la pantalla principal vemos como ahora tenemos 3 fuentes de datos



Aquí se muestran los datos nuevos, que aparecen en formato de texto:



Y vemos como volviendo a ejecutar una de las queries, los resultados cambian, en este caso tomamos como ejemplo el conteo de ventas por consola:

ALL RESULTS Showing 1 – 5 count results

Ventas : 20 consola : "sega"
Ventas : 21 consola : "nintendo"
Ventas : 35 consola : "play"
Ventas : 7 consola : "pc"
Ventas : 5 consola : "xbox"

Y tras la ejecución de la pipeline de agregación por videojuego también muestra nuevos datos:

ALL RESULTS Showing 1 – 6 count results

unidades : 5 nombre_juego : "Forza Horizon" consola : "xbox"
unidades : 35 nombre_juego : "The last of us" consola : "play"
unidades : 20 nombre_juego : "Sony" consola : "sega"
unidades : 15 nombre_juego : "Kirbi" consola : "nintendo"
unidades : 6 nombre_juego : "Mario y Luigi" consola : "nintendo"
unidades : 7 nombre_juego : "lol" consola : "pc"