

SPRINT 3 - Entornos Datawarehouse

Adrián Robles Arques

Pasos a seguir:

- **Crear un Data Lake en MongoDB Atlas:**
 - Nos conectamos a nuestro propio cluster
 - Seleccionar la base de datos “Tienda”.
 - Añadimos las colecciones.
 - Metemos nuestras colecciones de nuestra base de datos a las colecciones del Data Lake. Es decir, creamos la misma base de datos y nombre de colecciones del Data Lake.
 - Eliminamos la colección “Collection0”.
- **Conectamos desde MongoDB Compass.**
- **Ejecutamos una query para que nos dé los resultados esperados sobre ambas colecciones del Data Lake.**
- **Respondemos a la siguiente pregunta:**
 - ¿Cuál es el costo total de cada ticket? Como en la colección “ventas” está el ID del ticket y se repite porque varios productos han sido comprados algunas veces a la vez, tenemos que calcular el precio de cada ticket.

Crear un Data Lake en MongoDB Atlas

ADRIAN'S ORG - 2025-02-20 > PROJECT 0

Data Federation

Manage Query Limits

Create New Federated Database ▾

Fed-IEBS-AWS-Database-Master ⓘ

Connect

Configuration

...

Queries Executed / month	Total Data Processed / month	Total Data Returned / month	Average
11	110 MB	1.13 KB	763

Feed Downstream Systems

Export your data to Parquet, CSV, BSON, or Extended JSON and land it in Object Storage.

Explore with Sample Data

Try it with sample data preloaded into cloud object storage.

Query Data Across Clusters

Access and query data with a single connection.

Set up manually

Manually configure your Federated Database Instance.

Para esto haremos uso del servicio “Data Federation” en lugar del “Data Lake” como tal, seleccionando la opción de configuración manual.

A continuación, seleccionamos AWS como proveedor del servicio cloud y otorgamos un nombre apropiado para el Data Lake que vamos a crear.

Add Data Source

Choose Your Data Store to Get Started

Amazon S3

Azure Blob Storage

Google Cloud Storage

Atlas Cluster

HTTP(S)

Choose the Atlas clusters that you would like to access in your Federated Database instance.

Provide Namespaces in this project

IEBS

Search for database or collection ...

sample_mflix

Tienda



Cluster Read Preference >

Cluster Read Concern >


Cancel

Next

Después, elegimos como fuente de datos el propio MongoDB Atlas, y cargamos y seleccionamos la base de datos que habíamos creado. Eliminamos la colección virtual 0 que aparece por defecto, y creamos una apropiada para nuestra base de datos, añadiendo a continuación las dos colecciones correspondientes.



Y con esto, seleccionamos el botón “Create” y ya tenemos lista nuestro Data Lake en MongoDB. A continuación podemos conectarnos al mismo desde Compass. Para ello accedemos al apartado de conexiones de MongoDB Atlas, donde nos aparecen las diferentes opciones.



Seleccionando Compass nos aparecerán los datos de configuración para establecer una nueva conexión en la aplicación, seguimos los pasos en Compass cumplimentando el apartado marcado como <Contraseña>.

New Connection

Manage your connection settings

URI ⓘ

Edit Connection String 

mongodb://AdrianRobles:*****@data-lake-atlas-test1-zys7q.a.query.mongodb.net/?ssl=true&authSource=admin

Name

data-lake-atlas-test1-zys7q.a.query.mongod

Color

No Color

☐ Favorite this connection

Favoriting a connection will pin it to the top of your list of connections

➤ Advanced Connection Options

How do I find my connection string in Atlas?

If you have an Atlas cluster, go to the Cluster view. Click the 'Connect' button for the cluster to which you wish to connect.

[See example](#)

How do I format my connection string?

[See example](#)


Cancel

Save

Connect

Save & Connect

Y con esto establecemos finalmente la conexión desde Compass, teniendo acceso de lectura a los mismos.



The screenshot shows the MongoDB Compass interface. On the left, the 'CONNECTIONS (3)' sidebar lists the connected cluster 'data-lake-atlas-test1-zys7q.a.query.m...' and its sub-databases: 'Data_Lake_atlas', 'Productos', and 'Ventas'. The main panel displays the 'Data_Lake_atlas' database with two collections: 'Productos' and 'Ventas'. Both collections are marked as 'READ-ONLY'. The 'Productos' collection shows a 'Storage size' of 0 bytes, 0 documents, 0 average document size, 0 indexes, and 0 total index size. The 'Ventas' collection shows a 'Storage size' of 0 bytes, 0 documents, 0 average document size, 0 indexes, and 0 total index size. The top bar indicates the connection string 'data-lake-atlas-test1-zys7q.a.query.mongodb.net' and provides buttons for 'Open MongoDB shell' and 'Refresh'.

Ejecutar queries al Data Lake

data-lake-atlas-test1-zys7q.a.query.mongodb.net > Data_Lake_atlas > Productos READ-ONLY [Open MongoDB shell](#)

Documents N/A Aggregations Schema Indexes N/A Validation

Type a query: { field: 'value' } or [Generate query](#) [Explain](#) [Reset](#) [Find](#) [Options](#)

[EXPORT DATA](#) 25 1 - 5 of 5

```
_id: ObjectId('67d80237fc8ba670ded6e33a')
id: 1
name: "Camiseta"
category: "Camisetas"
price: 10.99
```

```
_id: ObjectId('67d80237fc8ba670ded6e33b')
id: 2
name: "Vestido"
category: "Vestidos"
price: 29.99
```

```
_id: ObjectId('67d80237fc8ba670ded6e33c')
id: 3
name: "Pantalon"
category: "Pantalones"
price: 20.5
```

```
_id: ObjectId('67d80237fc8ba670ded6e33d')
id: 4
name: "Chaqueta"
category: "Chaquetas"
price: 79.99
```


En la base de datos, si seleccionamos cualquiera de las dos colecciones, accedemos a todos los datos almacenados en ella, procedentes de las dos colecciones en MongoDB Atlas. Aquí podemos seleccionar los mismos procesos de filtrado y agregación que empleábamos sobre las colecciones previamente.

Respondemos a la siguiente pregunta

¿Cuál es el costo total de cada ticket? Como en la colección “ventas” está el ID del ticket y se repite porque varios productos han sido comprados algunas veces a la vez, tenemos que calcular el precio de cada ticket.

Para ello vamos a ejecutar una pipeline de queries con los siguientes pasos:

1. Cruzamos datos de artículos comprados en cada entrada con los precios de dicho artículo.



Stage 1: \$lookup

```
1 /**
2  * from: The target collection.
3  * localField: The local join field.
4  * foreignField: The target join field.
5  * as: The name for the results.
6  * pipeline: Optional pipeline to run on the
7  * let: Optional variables to use in the pipeline.
8  */
9 {
10   from: 'Productos',
11   localField: 'Producto',
12   foreignField: 'name',
13   pipeline: [
14     { $project: { 'price': 1, '_id': 0 } },
15   ],
16   as: 'Precio'
17 }
```

Output after \$lookup stage (Sample of 10 documents)

```
{
  "_id": ObjectId('67d80230fc8ba670ded6e334'),
  "ID ticket": 3,
  "Nombre del cliente": "Laura Fernández",
  "Producto": "Camiseta",
  "Fecha de compra": "2023-01-12T00:00:00.000+00...",
  "Precio": [
    {
      "price": 10.99
    }
  ]
}
```

Para esto usamos la función \$lookup, donde cruzamos datos de la colección Ventas con la de Productos, por el apartado nombre, y añadimos solo el precio, que se guarda en un array como un objeto.

2. Extraemos el dato del precio del objeto creado

Debido al formato de salida de la query anterior, el precio del producto ha quedado guardado como un objeto dentro de un array, aunque este solo contenga un dato. Para ello realizamos este proceso para extraer el dato.



Stage 2: \$set

```
1 /**
2  * field: The field name
3  * expression: The expression.
4  */
5 {
6   Precio: { $first: '$Precio.price' }
7 }
```

Output after \$set stage (Sample of 10 documents)

```
{
  "_id": ObjectId('67d80230fc8ba670ded6e334'),
  "ID ticket": 3,
  "Nombre del cliente": "Laura Fernández",
  "Producto": "Camiseta",
  "Fecha de compra": "2023-01-12T00:00:00.000+00...",
  "Precio": 10.99
}
```

3. Realizamos la agrupación por ID del ticket y sumamos los gastos

▼ Stage 3

```
1  ▾ /**
2    * _id: The id of the group.
3    * fieldN: The first field name.
4    */
5  ▾ {
6    _id: '$ID ticket',
7    Gasto: {
8      $sum: '$Precio'
9    }
10 }
```

Output after [\\$group](#) stage (Sample of 9 documents)

```
_id: 10
Gasto : 79.99
```

Por último, realizamos una agrupación por ID del ticket y sumamos el precio de cada artículo comprado en cada ticket, de forma que obtenemos el gasto final en cada ticket. Obteniendo el siguiente resultado:

ALL RESULTS		Showing 1 - 9 of 9	
▶	<pre>_id: 10 Gasto : 79.99</pre>		📄
	<pre>_id: 7 Gasto : 10.99</pre>		
	<pre>_id: 2 Gasto : 29.99</pre>		
	<pre>_id: 1 Gasto : 45.99</pre>		
	<pre>_id: 8 Gasto : 29.99</pre>		
	<pre>_id: 9 Gasto : 35</pre>		
	<pre>_id: 5 Gasto : 10.99</pre>		

Parte Opcional

Pasos a seguir (opcional):

- Acceder a AWS
- Acceder a S3
- Crear un bucket.
- Subir datos en formato JSON o CSV.
- Conectamos desde el Data Lake de MongoDB al S3.
- Meter el S3 en una colección existente y con el mismo esquema.
- Hacer una query sobre todos los datos.

Accedemos a S3, un servicio de AWS donde podemos crear espacios de cloud donde almacenar información. Estos espacios, llamados buckets, pueden contener diferentes tipos de ficheros. En este caso, crearemos un bucket de uso general, para ello, desde la pestaña de S3 con este nombre, usaremos el botón “Crear bucket”.

Amazon S3

Buckets de uso general

Buckets de directorio

Buckets de tablas

Concesiones de acceso

Puntos de acceso

Puntos de acceso del objeto

Lambda

Puntos de acceso de varias regiones

Operaciones por lotes

Analizador de acceso de IAM para S3

Configuración de bloqueo de acceso público correspondiente a

Instantánea de la cuenta: actualizada cada 24 horas

Ver panel de Storage Lens

Buckets de uso general

Buckets de directorio

Buckets de uso general (2)

Buscar buckets por nombre

Nombre	Región de AWS	Analizador de acceso de IAM	Fecha de creación
iebs-test-dl-1	Europa (Estocolmo) eu-north-1	Ver analizador para eu-north-1	21 Mar 2025 3:55:22 PM CET
mongodb-iebs-df-adrianroble	Europa (París) eu-west-3	Ver analizador para eu-west-3	21 Mar 2025 4:34:41 PM CET

Para ello, damos un nombre único al bucket, configuramos las características del mismo en la página que aparece a continuación, y acto seguido se creará y aparecerá disponible en la pestaña de buckets.

Crear bucket

Los buckets son contenedores de datos almacenados en S3.

Configuración general

Región de AWS

Europa (Estocolmo) eu-north-1

Tipo de bucket

Uso general

Directorio

Nombre del bucket

iebs-test-dl-1

Objetos (2)

[Copiar URI de S3](#) [Copiar URL](#) [Descargar](#) [Abrir](#) [Eliminar](#) [Acciones](#) [Crear carpeta](#) [Cargar](#)

Los objetos son las entidades fundamentales que se almacenan en Amazon S3. Puede utilizar el [inventario de Amazon S3](#) para obtener una lista de todos los objetos de su bucket. Para que otras personas obtengan acceso a sus objetos, tendrá que concederles permisos de forma explícita. [Más información](#)

Buscar objetos por prefijo

<

1

>

☐	Nombre	Tipo	Última modificación	Tamaño	Clase de almacenamiento
☐	 productos/	Carpeta	-	-	-
☐	 ventas/	Carpeta	-	-	-

Una vez creado, crearemos dos carpetas para contener los datos que nos disponemos a subir, con una estructura similar a los empleados en el ejercicio anterior. Acto seguido cargamos los ficheros desde el PC, ya sea desde un archivo CSV o JSON.

Se ha realizado la carga correctamente

Para obtener más información, consulte la tabla Archivos y carpetas.

Después de salir de esta página, la siguiente información ya no estará disponible.

Resumen

Destino

s3://mongodb-iebs-df-adrianrobles/productos/

Realizado correctamente

2 archivos, 147.0 B (100.00%)

Con errores

0 archivos, 0 B (0%)

Archivos y carpetas

Configuración

Archivos y carpetas (2 total, 147.0 B)

< 1 >

Nombre	Carpeta	Tipo	Tamaño	Estado	Error
productos_aws_mongodb.csv	-	text/csv	80.0 B	Realizado correctamente	-
productos_aws_mongodb_2.csv	-	text/csv	67.0 B	Realizado correctamente	-

Tras haber creado el bucket y cargado los datos, lo conectamos a MongoDB, para ello debemos seguir los mismos pasos iniciales que durante la creación del Data Lake anterior, pero esta vez cuando seleccionemos la fuente de los datos elegiremos AWS S3 en lugar de MongoDB Atlas.

Add Data Source

Choose Your Data Store to Get Started

[View Data Federation Docs](#)

Amazon S3

aws

Azure Blob Storage

Azure

Google Cloud Storage

Google Cloud

Atlas Cluster

MongoDB

HTTP(S)

Connect to AWS S3 and then map files from your S3 bucket to your Federated Database instance.

We'll guide you through the set up process

1. Setup an AWS IAM role for Data Federation access.
2. Grant access to the S3 bucket where you want to query and write data.
3. [Map data in S3 to virtual Databases and Collections](#) using our tools.

IAM > Roles > IEBS-DataLake-MongoDB-AdrianRobles

Identity and Access Management (IAM)

Buscar en IAM

Panel

Administración del acceso

Grupos de personas

Personas

Roles

IEBS-DataLake-MongoDB-AdrianRobles

Información

Eliminar

Editar

Resumen

Fecha de creación
March 21, 2025, 16:46 (UTC+01:00)

Última actividad
hace 1 hora

ARN
arn:aws:iam::050752631602:role/IEBS-DataLake-MongoDB-AdrianRobles

Duración máxima de la sesión
1 hora


Enlace para cambiar de rol en la consola
<https://signin.aws.amazon.com/switchrole?roleName=IEBS-DataLake-MongoDB-AdrianRobles&account=050752631602>

Para poder conectar nuestra base de datos en S3 con MongoDB, primero necesitamos crear un rol específico en la pantalla de IAM, de modo que permitamos a MongoDB acceder a nuestro recurso cloud dentro de AWS.

Con esto ya podemos terminar de configurar el Data Lake, añadimos en MongoDB los datos de nuestra base de datos en S3. Para ello, copiaremos las direcciones URI de las dos carpetas y las añadiremos al Data Lake

Define "Data Sources" Using Paths Inside Your S3

Bootstrap your path structure based on example files in your S3 Bucket. We will use components from the path to build a mapping syntax that lets DataLake use your queries to select relevant files to satisfy your queries.



Data Sources

Example S3 Path

Enter an example S3 Path from your bucket in AWS Console.

s3://mongodb-iebs-df-adrianrobles/productos/

Data Sources

Add Data Sources

Search data sources

Filter: All data sources

Add Data Source

AWS S3

S3 Store: mongodb-iebs-d...

/ventas

/productos

Federated Database Instance: Fed-IEBS-AWS-Database-Master

Visual JSON Save

Search database or collection name

Add Database

Data Source to Collections and Database Mapping

Map data from your Data Sources into Virtual Databases and Virtual Collections inside your Federated Database.

IEBS_test1

Productos

/productos

Drag the dataset to your Federated Database

Ventas

/ventas

Drag the dataset to your Federated Database

Finalmente tenemos accesibles los datos de nuestra base de datos en S3 en MongoDB Compass, desde donde podemos ver todo lo que está almacenado, así como realizar queries complejas. Si que se aprecia que los datos están guardados como strings, de modo que de querer emplear funciones de agregación y cálculos podría ser necesario convertirlos al formato apropiado.

DB-AWS-S3-IEBS-master > IEBS_test1

Sort byCollection Name

Open MongoDB shellRefresh

View

Productos

READ-ONLY

Storage size:

Documents:

Avg. document size:

Indexes:

Total index size:

Ventas

READ-ONLY

Storage size:

Documents:

Avg. document size:

Indexes:

Total index size:

DB-AWS-S3-IEBS-master > IEBS_test1 > Productos

READ-ONLY

Open MongoDB shell

Documents

N/A

Aggregations

Schema

Indexes

N/A

Validation

Type a query: { field: 'value' } or

Generate query

Explain

Reset

Find

Options

EXPORT DATA

25

1 - 4 of 4

ID_Producto : "1"

Nombre : "Curso de Data Warehouse"

Precio : "10€"

ID_Producto : "2"

Nombre : "Curso de ETL"

Precio : "20€"

ID_Producto : "3"

Nombre : "Curso de ML"

Precio : "40€"

ID_Producto : "4"

Nombre : "Curso de IA"

Precio : "30€"