

Extracción, Transformación y Carga de datos

Índice


1. Introducción a ETLs
 - 1.1 Contexto
 - 1.2 Obtención de datos
2. Características de Apache NiFi
 - 2.1 Componentes
 - 2.2 Casos de uso
 - 2.3 Arquitectura
3. Extracción, transformación y carga con Apache NiFi
 - 3.1 Conceptos
 - 3.2 Herramientas

Introducción a ETLs

¿Qué es un lago de datos?


- Se puede resumir de la siguiente manera: "Almacenar todo en un solo lugar y luego descubrir qué hacer con ello más tarde".
- Aunque esta puede ser la idea general de tu lago de datos, no obtendrás ningún valor real de esos datos hasta que establezcas una estructura lógica para ellos.
- Y es mejor que lleves un registro de tus metadatos de una forma u otra:
 - Riesgo: un lago lleno de datos, pero sin idea de lo que se encuentra bajo la brillante superficie.
- En algún momento, debes asignar un esquema a esos datos, especialmente si deseas consultarlos con SQL o algo similar.
- La pregunta eterna es si aplicar la valiente nueva estrategia de esquema sobre la lectura o seguir con el método probado y verdadero de esquema sobre la escritura.

¿Qué es un lago de datos?



Adquisición de datos

- El mecanismo para conectar dos repositorios de datos requiere dos interfaces:
 - Por un lado, están las interfaces que leen o aceptan los datos de las fuentes de contenido. La interfaz puede variar de una fuente a la siguiente.
 - La segunda interfaz se encuentra en el lado de destino, para escribir o enviar los datos al lago.



Adquisición de datos

- Orígenes heterogéneos:
 - Batch
 - Streaming



Limpieza de datos

- Eliminación de inconsistencias y errores de los conjuntos de datos originales.
- Eliminación de duplicaciones.
- Consistencia del esquema.
- Restringir datos según ciertos criterios.
- Calidad de los datos.
- La limpieza de datos puede ser un proceso que consume mucho tiempo y tedioso, pero no se puede ignorar.
- Podría requerir lógica de algoritmos.
- Previene la degradación de datos.
- Enriquecimiento de datos y metadatos.

Problema real

- **Situación**

- Tenéis 100 servicios corriendo en diferentes servidores que producen una cantidad inmensa de datos (como logs o datos en formato json) que deben de ser analizados y almacenados


- **Problema:**

- ¿Cómo enviar todos los logs y datos a un “data lake” basado en Hadoop?
- Necesitamos un sistema fiable, escalable y extensible...

Datos



datos



Etapas de un proyecto Big Data

- Etapa 1 - Obtención de Datos
- Etapa 2 - Preparación y Transformación de los Datos
- Etapa 3 - Almacenamiento
- Etapa 4 - Procesamiento
- Etapa 5 - Visualización

Etapas de un proyecto Big Data




¿Qué es la obtención de datos?

- “Es la etapa en proyectos BigData en la que se estudian los datos de la fuente origen, se establecen procesos para su tratamiento, y estos son volcados de manera coherente en sistemas de almacenamiento.”
- Minería de datos + Nuevas tecnologías = Obtención de datos




¿Qué es para los equipos la obtención de datos?

- “Es una etapa crucial, necesaria y a menudo infravalorada.” José Felipe Ortega, Científico de Datos de la URJC



Retos de la obtención de datos

- Gestión de múltiples fuentes de datos: Online vs Offline



Retos de la obtención de datos

- Técnicas de Obtención: Scraping/Crawlers, Streaming, APIs, SDKs, HomeBrew/Direct...



Retos de la obtención de datos

- Diferentes formatos de representación

Teoría Pokemon



Retos de la obtención de datos

- Diferentes formatos de representación

Ejemplo

Oracle	Kettle	Java		Cassand ra
Number	Integer	Integer		Int


Retos de la obtención de datos

- Consolidación de los datos obtenidos
 - En campos de tipo Fecha nos encontramos con Descripciones
 - En campos de tipo Numérico nos encontramos con Fechas

...(infinitas combinaciones cuyo cometido es enfurecer al equipo)

Retos de la obtención de datos

- Construcción de Módulos/Plugins intercambiables para manejar cada tipo de fuente...



Retos de la obtención de datos


- ...por lo que debemos considerar diseños de colas de datos de entrada que gestionen:
 - Diferentes velocidades
 - Datos heterogéneos
 - Mantenimiento del orden de llegada

Retos de la obtención de datos

- Importa la velocidad de ejecución:
 - En flujos de datos en tiempo real podemos perder datos si no los recuperamos a tiempo.
 - Los tiempos de espera para fuentes muy grandes se pueden alargar demasiado (días, semanas, años)

Retos de la obtención de datos

- Límite de las fuentes: VENDOR LOCK-IN



Técnicas de obtención de datos

- Propuestas

Procesamiento Batch vs Procesamiento Stream




Técnicas de obtención de datos

- Propuestas batch:
 - Sqoop
 - MongoDB
 - Cassandra
 - Hive
 - Pentaho - kettle
 - HBase
 - Hadoop
 - Spark

Técnicas de obtención de datos

- Sqoop



Técnicas de obtención de datos

- Procesos manuales



- Desarrollar desde 0 un programa para lanzar múltiples instancias del comando (secuencialmente, ya que paralelamente estaba sujeto a errores de concurrencia)
- Paralelizable en varios nodos manualmente

Técnicas de obtención de datos

- Pentaho Data Integration - kettle



- Gran herramienta para tratamiento de datos
- Gran comunidad detrás
- Interfaz amigable
- Poco práctica en “El Mundo Real TM” actualmente para ingestar volumen BigData

Técnicas de obtención de datos

- Propuestas Streaming:
 - Apache Flume
 - Logstash
 - Kafka
 - Oozie
 - Apache Storm
 - Samza
 - Spark Streaming

Técnicas de obtención de datos


- Flume



- Herramienta exclusiva para la etapa de Obtención de datos
 - Source
 - Channel
 - Sink
 - Interceptor

Técnicas de obtención de datos

- Flume




Técnicas de obtención de datos

- Aproximación ETL (Extract, Transform, Load)




Técnicas de obtención de datos

- Algunos ejemplos




Técnicas de obtención de datos

- Algunos ejemplos



Técnicas de obtención de datos


- Algunos ejemplos



Técnicas de obtención de datos

- Algunos ejemplos


Canonical Stream Processing Architecture



Técnicas de obtención de datos


- Algunos ejemplos

Storm-Kafka Pipelines




Técnicas de obtención de datos

- Algunos ejemplos



Técnicas de obtención de datos

- Algunos ejemplos



Características de Apache NiFi

¿Qué es un flujo de datos (dataflow)?


- Mover algún contenido del punto A al punto B
- El contenido puede ser cualquier flujo de bytes:
 - Logs
 - HTTP
 - XML
 - CSV
 - Imágenes
 - Vídeo
 - Telemetría
- Productores
 - Cosas
 - Cualquier cosa
 - Todo
- Consumidores:
 - Usuarios
 - Persistencias
 - Sistemas
 - Más cosas...

Los retos en un flujo de datos en 3 categorías

- Datos:
 - Estándares
 - Formatos
 - Protocolos
 - Veracidad de la información
 - Validez de la información
 - Esquemas
 - Particionamiento
- Infraestructura:
 - Envío “Exactly once”
 - Asegurar la seguridad
 - Adaptarse a la seguridad
 - Gestión de credenciales
 - Redes de comunicación
- Personas:
 - Cumplimiento
 - Esa [personalequipolgrupo]
 - Los consumidores cambian
 - Los requisitos cambian

Los retos en un flujo de datos en 3 categorías

- Conectemos los puntos de As con Bs, luego As a Cs, Bs a Ds, Cs a Fs



¿Por qué NiFi?

- Era de la información: de una economía basada en la industria a una economía basada en la informática → enormes cantidades de datos almacenados
- Los lagos de datos de Hadoop carecen de componentes para el movimiento de datos
- NiFi, en un solo panel, logra la capacidad de
 - Conectar bases de datos
 - Servidores de archivos
 - Clústeres de Hadoop
 - Colas de mensajes
 - Dispositivos entre sí
- NiFi proporciona a las organizaciones una plataforma distribuida y resiliente para construir sus flujos de datos empresariales
- Interfaz de usuario (UI) de arrastrar y soltar, que permite a los administradores crear flujos de datos visuales y manipular los flujos en tiempo real
- Proporciona al usuario información relacionada con auditorías, linaje y backpressure

Flujo de datos (dataflow)

- Interfaz de usuario basada en web para crear, supervisar y controlar flujos de datos.
- Gráficos directos de enrutamiento y transformación de datos.
- Altamente configurable: modifica el flujo de datos en tiempo de ejecución, prioriza dinámicamente los datos.
- Fácilmente ampliable a través del desarrollo de componentes personalizados:
 - <https://nifi.apache.org/developer-guide.html>
- Data provenance (procedencia de los datos) rastrea los datos a lo largo de todo el sistema.

Características clave

- Entrega garantizada
- Almacenamiento en búfer de datos
 - Contrapresión (backpressure)
 - Liberación de presión
- Colas con prioridad
- Calidad de servicio (QoS) específica para el flujo
 - Latencia (ms) frente a rendimiento/throughput (OPS)
 - Tolerancia a la pérdida
- Procedencia de los datos
- Compatible con modelos de envío (push) y extracción (pull).
- Recuperación/registro de un historial detallado a nivel de grano fino.
- Comando y control visual.
- Plantillas de flujo.
- Seguridad enchufable y multi-tenant.
- Diseñado para ser extensible.
- Agrupación (clustering)

Programación Basada en Flujos (FBP)

Término FBP	Término NiFi Term	Descripción
Information Packet	FlowFile	Cada objeto que se mueve a través del sistema
Black Box	FlowFile Processor	Realiza el trabajo, realizando alguna combinación de enrutamiento de datos, transformación o mediación entre sistemas
Bounded Buffer	Connection	El enlace entre procesadores, actuando como colas y permitiendo que varios procesos interactúen a diferentes velocidades
Scheduler	Flow Controller	Mantiene el conocimiento de cómo están conectados los procesos y gestiona los hilos y asignaciones que todos los procesos utilizan
Subnet	Process Group	Un conjunto de procesos y sus conexiones, que pueden recibir y enviar datos a través de puertos. Un grupo de procesos permite la creación de un componente completamente nuevo simplemente mediante la composición de sus componentes

FlowFiles y Agnosticismo de Datos

- ¡NiFi es agnóstico de datos!
- Sin embargo, NiFi fue diseñado teniendo en cuenta que los usuarios pueden preocuparse por detalles específicos y proporciona herramientas para interactuar con formatos y protocolos específicos, etc.
- Principio de robustez:
 - Sé conservador en lo que haces, sé liberal en lo que aceptas de otros.

FlowFiles son como datos HTTP

HTTP data

FlowFile

```
HTTP/1.1 200 OK
Date: Sun, 10 Oct 2010 23:26:07 GMT
Server: Apache/2.2.8 (CentOS) OpenSSL/0.9.8g
Last-Modified: Sun, 26 Sep 2010 22:04:35 GMT
ETag: "45b6-834-49130cc1182c0"
Accept-Ranges: bytes
Content-Length: 13
Connection: close
Content-Type: text/html
```

Hello world!

Header


```
Standard FlowFile Attributes
Key: 'entryDate' Value: 'Fri Jun 17 17:15:04 EDT 2016'
Key: 'lineageStartDate' Value: 'Fri Jun 17 17:15:04 EDT 2016'
Key: 'fileSize' Value: '23609'
FlowFile Attribute Map Content
Key: 'filename' Value: '15650246997242'
Key: 'path' Value: './'
```

Content

*Binary Content **

Profunda integración con el ecosistema Big Data

- Más de 300 procesadores y más de 100 controladores de servicios



Extensiones y puntos de integración


Término NiFi	Descripción
Flow File Processor	Comportamiento Push/Pull. Interfaz customizable
Reporting Task	Se utiliza para enviar datos desde NiFi a algún servicio externo (métricas, procedencia, etc.)
Controller Service	Se utiliza para habilitar componentes reutilizables / servicios compartidos en todo el flujo.
REST API	Permite a los clientes conectarse para extraer información, cambiar el comportamiento, etc.

Casos de Uso de NiFi

- Aspectos a tener en cuenta al planificar un proyecto de NiFi
 - Volumen y velocidad de los datos
 - Los archivos de un directorio pueden requerir mucha memoria.
 - Los datos de un puerto TCP requieren procesamiento continuo.
 - Tipos de datos a ingerir
 - Conjuntos de datos binarios y de texto.
 - Capacidad de los sistemas conectados
 - De acuerdo con las capacidades de cada uno de los sistemas conectados para aceptar los datos a medida que están disponibles, considere la posibilidad de admitir el almacenamiento temporal de datos de contenido y almacenar los datos a largo plazo.


Casos de Uso de NiFi

- Importando un conjunto de datos a una base de datos
 - Monitorizar un directorio en el disco y, de manera programada, leer todos los archivos en el directorio, validar los datos en esos archivos y, finalmente, escribir los registros válidos en una base de datos.



Casos de Uso de NiFi


- Escuchando peticiones Posts en HTTP
 - Un sistema externo envía los datos a través de una conexión HTTP a NiFi utilizando la opción POST. El enfoque para configurar una operación de escucha es tan sencillo como insertar el procesador ListenHTTP.



Processor Details		
Required field		
Property		Value
Base Path	?	contentListener
Listening Port	?	7001
Max Data to Receive per Second	?	No value set
SSL Context Service	?	No value set
Authorized DN Pattern	?	.*
Max Unconfirmed Flowfile Time	?	60 secs
HTTP Headers to receive as Attributes (Regex)	?	No value set

Casos de Uso de NiFi

- Sondeo (polling) de una API RESTful para extraer un atributo JSON
 - El flujo ejecuta consultas RESTful cada 30 segundos y luego guarda el resultado como un atributo de NiFi para su uso en otras funciones posteriores.




Configure Processor		
SETTINGS	SCHEDULING	PROPERTIES
COMMENTS		
Required field		
Property	Value	
Destination	?	flowfile-attribute
Return Type	?	auto-detect
Path Not Found Behavior	?	ignore
Null Value Representation	?	empty string
wind_speed	?	\$.query.results.channel.wind_speed

Arquitectura


- Cliente HTTP: La interacción con la API puede ir a cualquier nodo.
- Clustering:

- Alta disponibilidad
- Escalabilidad
- Balanceo de carga
- Tolerancia a fallos
- Particionamiento
- Replicación




Arquitectura

- Cliente HTTP: La interacción con la API puede ir a cualquier nodo.
 - Para cada instancia, será necesario actualizar ciertas propiedades en el archivo nifi.properties.





Arquitectura

- Repositorios





Arquitectura

- Repositorios: paso por referencia



Arquitectura

- Repositorios: copia en la escritura



Extracción, transformación y carga con Apache NiFi

Conceptos básicos de NiFi

- Un conjunto de datos fluye a través de múltiples etapas de lógica, transformación y enriquecimiento.
- NiFi es un controlador de información híbrido y procesador de eventos.
- Considera el flujo de información como una serie de eventos distintos en lugar de una operación por lotes.
- Considera una base de datos SQL como un conjunto de filas individuales en el momento de la ingestión.
 - Enriquece los datos.
 - Cada fila se analiza de manera individual.
 - Un valor corrupto solo hace que un evento falle, no todo el procedimiento.

Conceptos básicos de NiFi: FlowFiles

- Dos partes:
 - Atributos
 - Conjunto predeterminado de atributos + atributos adicionales agregados en las operaciones
 - Los atributos se manipulan mediante el lenguaje de expresión de NiFi
 - Contenido
 - Es la información y puede ser referenciada por los procesadores

Conceptos básicos de NiFi: FlowFiles processors

- Código autocontenido con entradas y salidas
- Ejemplos
 - GetFTP, recupera archivos de un servidor FTP y crea un flujo de datos.
 - Incluye atributos sobre el directorio, la fecha de creación y el nombre del archivo.
 - Contenido: contenido del archivo.
 - RouteOnAttribute, examina un flujo de datos entrante y aplica lógica definida por el usuario en función de los atributos antes de pasarlo a lo largo de la cadena.

Conceptos básicos de NiFi: Connections

- Especifica cómo los flujo de datos viajan entre procesadores.
- Las conexiones comunes son para éxito y fallo.
- Procesadores como RouteOnAttribute tienen conexiones personalizadas basadas en las reglas creadas.
- Las conexiones pueden ser auto-terminadas para descartar un tipo específico de evento.
- Funciones avanzadas como la contrapresión.

Conceptos básicos de NiFi: Flowfile processors tabs

- Configuración:
 - nombre y relaciones de auto-terminación (incluidas las personalizadas)
- Programación:
 - Estrategia basada en temporizador
 - Intervalo específico o lo antes posible (asap)
 - Concurrencia
- Comentarios
- Propiedades
 - Configuraciones específicas del procesador
 - Puede permitir propiedades personalizadas
 - Algunos admiten el Lenguaje de Expresión (Expression Language).

NiFi Expression Language

- Permite interactuar con atributos (metadatos)
- `${atributo}`
- Ejemplo: `GetFile` —> `${ruta}`
- Términos para expresiones de transformación y lógica, como `contains` o `append`
 - Comprobar si el archivo tiene un nombre específico
 - `${filename:contains('NiFi')}`
 - Agregar un nuevo directorio al atributo de ruta
 - `${path:append('/nuevo_directorio')}`
 - Reformatear una fecha
 - `${string_date:toDate("yyyy-MM-DD")}`
 - Operaciones matemáticas
 - `${amount_owed:minus(5)}`
 - Mayor que en múltiples variables
 - `${variable_uno:gt(${variable_dos})}`

JSONPath

- Utilizado por procesadores como EvaluateJsonPath.
- La jerarquía JSON se referencia con un \$ para representar la raíz, y los nombres de los campos anidados obtienen un valor, como \$.cuenta.nombre_usuario.primer_nombre.
- Para enumerar una lista de cuentas: \$.cuenta[0].nombre_usuario.primer_nombre.
- Operaciones adicionales más complejas:
 - Buscar en cualquier nivel de JSON un campo llamado "Version"
 - \$..Version.
 - Filtrar solo las subversiones mayores que 5
 - \$..Versión[?(@.subVersion>5)]

XPath/XQuery

- Para acceder a datos en archivos XML
- Procesadores: EvaluateXPath, EvaluateXQuery...
- Acciones
 - Especificar el valor del primer nombre del titular de la cuenta
 - `/cuenta/nombre_usuario/primer_nombre`
 - Especificar el valor de la primera cuenta si hay varias cuentas en el XML
 - `/cuenta[0]/nombre_usuario/primer_nombre`
 - Buscar en cualquier nivel de XML un campo llamado "Version"
 - `//Version`
 - Filtrar solo las subversiones mayores que 5
 - `//Version[subVersion>5]`

Herramientas: MiNiFi

- Retos en IoT
 - Capacidad de cómputo limitada
 - Potencia/red limitadas
 - Disponibilidad limitada de bibliotecas/plataformas de software
 - Sin interfaz de usuario (UI)
 - Inaccesible físicamente
 - No actualizado con frecuencia
 - Estándares/protocolos en competencia
 - Escalabilidad
 - Privacidad y seguridad

Herramientas: MiNiFi al rescate

- Coloca las partes clave de NiFi cerca de donde comienza los datos y proporciona comunicación bidireccional.
- NiFi se encuentra en el centro de datos: dale un servidor empresarial o un conjunto de ellos.
- MiNiFi se encuentra tan cerca como sea posible de donde se generan los datos y es un invitado en ese dispositivo o sistema.
 - IoT (Internet de las cosas)
 - Coche conectado
 - Hardware heredado
- MiNiFi Java
 - Sin interfaz de usuario (UI)
 - Configuración en YAML
 - Más de 60 procesadores

Herramientas: ¿Cómo se integra MiNiFi con NiFi?

- **NiFi**
 - Diseñar flujos
 - Agrupar datos de muchas fuentes
 - Realizar enrutamiento/análisis/Procesamiento de Eventos Complejos (SEP)
- **MiNiFi**
 - Recibir flujos
 - Recopilar datos
 - Enviar para procesamiento

Herramientas: ¿Qué proporciona MiNiFi?

- Etiquetado de datos/procedencia
- Gobernanza desde el origen (restricciones geográficas)
- Seguridad (encriptación, autenticación basada en certificados)
- Baja latencia (reacciones en toma de decisiones inmediatas)

Herramientas: Extracción con MiNiFi

- De sitio a sitio
 - Protocolo NiFi
 - Dos implementaciones
 - Socket en bruto
 - HTTP(S)
- Asegurado con autenticación mutua TLS
 - HTTP(S), (S)FTP, JMS, Syslog, Archivo, Correo electrónico, Proceso

Herramientas: Registry

- Es una aplicación complementaria que proporciona un lugar central para el almacenamiento y la gestión de recursos compartidos en una o más instancias de NiFi y/o MiNiFi.
- Los objetivos específicos para el esfuerzo inicial del Registro incluyen:
 - Implementación de un Registro de Flujos para almacenar y gestionar flujos versionados.
 - Integración con NiFi para permitir el almacenamiento, recuperación y actualización de flujos versionados desde un Registro de Flujos.
 - Administración del Registro para definir usuarios, grupos y políticas.

Herramientas: FDS (Flow Design System)

- Un subproyecto de Apache NiFi diseñado para proporcionar una experiencia de usuario coherente en las diversas aplicaciones web dentro del ecosistema de NiFi.
- Características:
 - El Sistema de Diseño de Flujos (Flow Design System), un subproyecto de Apache NiFi, es una plataforma reutilizable y atómica que proporciona un conjunto coherente de componentes de interfaz de usuario (UI/UX) para Apache NiFi, Apache NiFi Registry, Apache NiFi MiNiFi y cualquier otra aplicación web de código abierto que desee utilizarlos.
 - Los objetivos específicos para el esfuerzo inicial del Sistema de Diseño de Flujos incluyen:
 - Implementación del Sistema de Diseño de Flujos para componentes de UI/UX reutilizables.
 - Integración con la interfaz de usuario/experiencia de usuario (UI/UX) de NiFi Registry a través del registro público npm.

¡Gracias!