

TUTORIAL Sprint 4

Para la realización del proyecto del Sprint 4, es imprescindible haber realizado el proyecto del Sprint anterior y visionar el video tutorial de este sprint. Este documento es un resumen de los comandos utilizados en dicho video tutorial.

Comandos HDFS

1. Abrir un terminal dentro de la máquina virtual y establecer el directorio de instalación de Hadoop como directorio actual
 - `cd /home/bigdata/hadoop-3.3.6/`
2. Arrancar HDFS
 - `sbin/start-dfs.sh`
3. Más adelante en el tutorial, cuando se hayan creado datos nuevos a través de la consulta de Hive, se podrá listar el contenido de la carpeta que los contiene
 - `bin/hdfs dfs -ls /data/test`

```
bigdata@bigdatapc:~$ cd /home/bigdata/hadoop-3.3.6/
bigdata@bigdatapc:~/hadoop-3.3.6$ sbin/start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [bigdatapc]
bigdata@bigdatapc:~/hadoop-3.3.6$
```

WebUI de HDFS

Cuando arrancamos HDFS, se arranca también una WebUI que nos aporta información general sobre el cluster de HDFS (Namenode, Secondary Namenode y Datanode) y también incluye una serie de utilidades donde destaca un navegador del sistema de ficheros de HDFS. Para utilizar esta funcionalidad se deben seguir los siguientes pasos:

1. Abrir el navegador de FireFox de la máquina virtual
2. Dirigirse a la url <http://localhost:9870>
3. Click en la pestaña Utilities que se encuentra a la derecha dentro de la franja verde de la parte superior
4. En el desplegable que aparece, click en Browse the file system


The screenshot shows the HDFS WebUI interface. At the top, there's a navigation bar with tabs: Hadoop, Overview, Datanodes, Datanode Volume Failures, Snapshot, Startup Progress, and Utilities. The Utilities tab is selected, and a dropdown menu is open, showing options: Browse the file system, Logs, Log Level, Metrics, Configuration, Process Thread Dump, and Network Topology. The main content area displays the Overview for 'localhost:9000' (active). Below this, there's a table with system information.

Started:	Tue Oct 24 15:02:21 +0200 2023
Version:	3.3.6, r1be78238728da9266a4f88195058f08fd012bf9c
Compiled:	Sun Jun 18 10:22:00 +0200 2023 by ubuntu from (HEAD detached at release-3.3.6-RC1)
Cluster ID:	CID-3ab5777d-43ce-4df6-b71a-5604a3260017
Block Pool ID:	BP-495285225-127.0.1.1-1697135071914

Comandos de la plataforma Confluent (Ecosistema Kafka)

La plataforma Confluent es una plataforma basada en Kafka y que tiene 2 versiones: una comercial y otra Open-Source (esta última es la que está instalada en la máquina virtual y es la que utilizaremos para los Sprints). A continuación se detallan los comandos utilizados en el vídeo tutorial de este Sprint:

1. Dirigirse a la carpeta de instalación de Confluent
 - `cd /home/bigdata/confluent-7.5.1/`
2. Arrancar Kafka y todos los servicios requeridos para ello (Zookeeper)
 - `confluent local services kafka start`
3. Arrancar un consumidor de Kafka (NO Avro) del topic test para comprobar que los datos se introducen correctamente en este topic
 - `bin/kafka-console-consumer --bootstrap-server localhost:9092 --topic test`
 - Más adelante, cuando se haya ya ejecutado el flujo de datos de NiFi, este consumidor se puede detener situándose en su terminal y realizando la combinación de teclas Control+C



```
Kafka
bigdata@bigdatapc: ~/confluent-7.5.1 183x10

The local commands are intended for a single-node development environment only, NOT for production usage. See more: https://docs.confluent.io/current/cli/index.html
As of Confluent Platform 8.0, Java 8 will no longer be supported.

Using CONFLUENT_CURRENT: /tmp/confluent.897188
Starting ZooKeeper
ZooKeeper is [UP]
Starting Kafka
Kafka is [UP]
bigdata@bigdatapc:~/confluent-7.5.1$ bin/kafka-console-consumer --bootstrap-server localhost:9092 --topic test
```

Flujo de datos con NiFi

Vamos a arrancar el servicio de NiFi para poder desarrollar flujos ETL a través de la creación de un Processor Group. Para ello, se deben seguir los siguientes pasos:

1. Dirigirse a la carpeta de instalación de NiFi
 - `cd /home/bigdata/nifi-1.23.2/`
2. Arrancar el servicio de NiFi, el cual también incluye la WebUI para poder diseñar un flujo de datos con la creación de un Processor Group. La WebUI puede tardar alrededor de 1 minuto en estar operativa
 - `bin/nifi.sh start`
3. Vamos a lanzar el comando tail interactivo (opción -f) de Ubuntu para poder visualizar las últimas 400 líneas del log de NiFi
 - `tail -400f /home/bigdata/nifi-1.23.2/logs/nifi-app.log`
 - Más adelante, cuando se termine este ejemplo, para detener tail, nos debemos situar en su terminal y realizar Control+C
4. Ahora nos dirigimos a FireFox para abrir una nueva pestaña y cargar la WebUI de NiFi
 - URL: <https://127.0.0.1:8443/nifi/>
 - Usuario: bigdata
 - Contraseña: bigdata123456
5. Es imprescindible visualizar el vídeo tutorial y entender cómo se genera el flujo de datos de ejemplo de este Sprint. De hecho, es altamente recomendable reproducir los pasos de la creación del flujo de datos de ejemplo en vuestras máquinas virtuales. Adicionalmente, se aporta el fichero Test.xml de NiFi que contiene el diseño de dicho flujo de datos de ejemplo. Para cargar esta plantilla, se deben seguir los pasos que se especifican en la documentación oficial de NiFi
 - https://nifi.apache.org/docs/nifi-docs/html/user-guide.html#Import_Template

```


bigdata@bigdatapc:~$ cd /home/bigdata/nifi-1.23.2/
bigdata@bigdatapc:~/nifi-1.23.2$ bin/nifi.sh start

Java home: /usr/lib/jvm/java-8-openjdk-amd64
NiFi home: /home/bigdata/nifi-1.23.2

Bootstrap Config File: /home/bigdata/nifi-1.23.2/conf/bootstrap.conf

bigdata@bigdatapc:~/nifi-1.23.2$ tail -400f /home/bigdata/nifi-1.23.2/logs/nifi-app.log

```



Shell de Hive

Una vez que el flujo de NiFi está preparado, vamos a utilizar Hive para insertar datos en la ruta de HDFS donde dicho flujo está esperando datos. Para ello, vamos a utilizar beeline que es una consola que proporciona Hive para poder lanzar consultas HiveQL:

1. Abrir un terminal nuevo y dirigirse a la carpeta de instalación de Hive
 - `cd /home/bigdata/apache-hive-3.1.3-bin/`
2. Arrancar el terminal beeline
 - `bin/beeline -u jdbc:hive2://`
3. Una vez dentro del terminal, crear una tabla en la ruta /data/test (donde el flujo de datos de NiFi está esperando datos) que contenga el resultado de realizar una consulta analítica sobre la tabla shops
 - `CREATE TABLE test STORED AS parquet LOCATION '/data/test/' AS SELECT max(budget) AS max_budget, city FROM shops GROUP BY city;`
4. Salir de beeline
 - `!q`

```
bigdata@bigdatapc:~/hadoop-3.3.6$ cd /home/bigdata/apache-hive-3.1.3-bin/  
bigdata@bigdatapc:~/apache-hive-3.1.3-bin$ bin/beeline -u jdbc:hive2://
```


```
Connected to: Apache Hive (version 3.1.3)  
Driver: Hive JDBC (version 3.1.3)  
Transaction isolation: TRANSACTION_REPEATABLE_READ  
Beeline version 3.1.3 by Apache Hive  
0: jdbc:hive2://> CREATE EXTERNAL TABLE shops(id int, name string, city string, budget double) STORED AS parquet LOCATION '/test/shops/';  
OK  
No rows affected (0.989 seconds)  
0: jdbc:hive2://> SELECT max(budget) AS max_budget, city FROM shops GROUP BY city;
```

Detener flujo de datos de NiFi

Una vez que ya tenemos los datos en HDFS y se ha creado la tabla en Hive, ya podemos detener el servicio de NiFi

Por un lado, vamos a detener todos los Processors del Processor Group. Para ello, se deben seguir los siguientes pasos:

1. Click en el fondo del Canvas del Processor Group para que el contexto del menú de acciones se refiera al Processor Group, no a ningún Processor en concreto
2. Click en el símbolo de la acción Stop



Por otro lado, desde la terminal, parar todos los servicios de NiFi:

1. `cd /home/bigdata/nifi-1.23.2/`
2. `bin/nifi.sh stop`

```
bigdata@bigdatapc:~/nifi-1.23.2$ bin/nifi.sh stop
Java home: /usr/lib/jvm/java-8-openjdk-amd64
NiFi home: /home/bigdata/nifi-1.23.2
Bootstrap Config File: /home/bigdata/nifi-1.23.2/conf/bootstrap.conf
2023-10-25 17:47:35,045 INFO [main] org.apache.nifi.bootstrap.Command Apache NiFi has accepted the Shutdown Command and is shutting down now
2023-10-25 17:47:35,058 INFO [main] org.apache.nifi.bootstrap.Command NiFi PID [25896] shutdown in progress...
```

Detener servicios de Confluent

Una vez que ya hemos comprobado que los datos se han cargado correctamente en HDFS y que hemos creado una tabla en Hive con esos datos, ya se pueden detener los servicios de Confluent (Kafka, Zookeeper):

- `confluent local services stop`

```
bigdata@bigdatapc:~/confluent-7.5.1$ confluent local services stop
The local commands are intended for a single-node development environment only, NOT for production usage. See more: https://docs.confluent.io/current/cli/index.html
As of Confluent Platform 8.0, Java 8 will no longer be supported.

Using CONFLUENT_CURRENT: /tmp/confluent.016675
Control Center is [DOWN]
ksqlDB Server is [DOWN]
Stopping Connect
Connect is [DOWN]
Kafka REST is [DOWN]
Stopping Schema Registry
Schema Registry is [DOWN]
Stopping Kafka
```

Detener HDFS

Una vez terminado el ejercicio, es imprescindible parar el servicio de HDFS adecuadamente para evitar que se puedan corromper el sistema de ficheros de HDFS:

1. Desde un terminal, dirigirse a la carpeta de instalación de Hadoop
 - `cd /home/bigdata/hadoop-3.3.6/`
2. Ejecutar el script que detiene Namenode, Secondary namenode y Datanode
 - `sbin/stop-dfs.sh`

```
bigdata@bigdatapc:~/hadoop-3.3.6$ sbin/stop-dfs.sh
Stopping namenodes on [localhost]
Stopping datanodes
Stopping secondary namenodes [bigdatapc]
bigdata@bigdatapc:~/hadoop-3.3.6$
```

Salir de la máquina virtual

Una vez que se ha detenido HDFS, ya podemos apagar la máquina virtual:

1. Dentro de la máquina virtual, click en el símbolo de la energía en la parte superior del estado de Ubuntu
2. Click en la opción Apagar / cerrar sesión
3. Click en Apagar...

